Physical AI 講座応用編 1 最終課題レポート

提出日：2026 年 11 月 1 日

提出者：宇野幸登

1. 概要

本研究では、ROS 2 Humble と Gazebo 上の CRANE+ V2 を用い、5 cm の木製ブロックを把持して別の位置へ搬送し、目標領域で解放する Pick and Place を模倣学習で実現した。MoveIt 2 による教師動作を rosbag2 へ記録し、品質検査を通過した 20 エピソード、12,444 フレームを LeRobotDataset へ変換した。学習には Action Chunking with Transformers を用い、学習と推論は CPU 上で実施した。

最終モデルは 670,243 パラメータで、5,000 ステップ学習した。Gazebo で 5 回評価した結果、接近、把持、持上げ、搬送、配置の全工程で 5 回すべて成功した。平均最大持上げ量は 17.96 cm、平均平面移動量は 32.40 cm だった。一方、5 回中 3 回はブロックがテーブル面より約 2.5 cm 高い位置に残り、搬送成功と安定した静置には差があることも確認した。

2. 目的

本研究の目的は、CRANE+ V2 の関節状態だけを観測として、木製ブロックの接近、把持、持上げ、搬送、配置を一連の方策として学習できるかを検証することである。特に、教師動作の物理的な成功を Gazebo の物体座標で確認し、成功データだけを用いて学習することで、模倣学習による Pick and Place の再現性を評価する。

評価では、学習 loss だけでなく、対象物の持上げ量、平面移動量、最終位置、グリッパ状態を測定する。また、ACT が出力する action chunk と ROS 2 trajectory controller の追従特性が動作へ与える影響を調べ、モデルと制御系を組み合わせた実行条件を明らかにする。

3. 方法

3.1 実験環境と処理構成

ロボットの動作計画には MoveIt 2、物理シミュレーションには Gazebo Ignition を使用した。観測と行動は CRANE+ V2 の 5 関節で構成し、画像やブロック座標は ACT の入力に含めなかった。学習時のブロック初期位置は固定し、制御周期は 20 Hz とした。

- **実行環境**：Windows 11 と Docker Desktop
- **コンテナ**：physical_ai_final
- **ロボット環境**：ROS 2 Humble、Gazebo Ignition、MoveIt 2、CRANE+ V2
- **学習環境**：LeRobot、ACT、PyTorch、CPU 学習
- **観測と行動**：5 次元関節状態と 5 次元関節指令、20 Hz

処理は、教師動作の生成、データ記録、データセット変換、ACT 学習、Gazebo 評価の順に進む。教師ノードは接近、把持、持上げ、搬送、配置、解放、退避を実行し、関節状態、関節指令、グリッパ指令、工程ラベルを rosbag2 に記録する。推論時は、学習済み ACT が現在の関節状態から将来 32 点の関節指令を予測し、ROS 2 trajectory controller へ送信する。

3.2 教師データの作成

ACT 学習へ進む前に、MoveIt 2 の Pick and Place サンプルを用いて、対象ブロックが実際に持ち上がり、別位置へ移動することを確認した。対象の Wood cube 5cm は質量 0.0565 kg の動的物体であり、衝突形状と慣性を持つ。初回は MoveIt と DDS の負荷によって失敗したが、RViz を終了して CPU 負荷を下げ、ノードと controller を再起動すると完走した。

- **初期位置**：約 (0.000, -0.100, 1.015) m
- **最大高さ**：1.19937 m
- **最大持上げ量**：0.18437 m
- **終了位置**：約 (0.252, 0.004, 1.065) m

教師データは 2 回の収集バッチで 27 試行を取得した。Gazebo の物体位置、工程ラベル、グリッパ指令を用いて品質を検査し、8 工程が揃って実把持にも成功した 20 エピソードを採用した。教師軌道は接近開始から退避開始直前までを使用し、初期姿勢と退避後姿勢が近いことによる時間的な曖昧さを抑えた。

3.3 ACT の学習と推論条件

最初に VAE を有効にした ACT を 2,000 ステップ学習したが、開始姿勢で不要な指令が発生し、Gazebo 評価では搬送に至らなかった。今回の教師データは固定位置から生成され、軌道のばらつきも小さいため、最終モデルでは VAE encoder を無効にし、action chunk prediction を担う transformer は維持した。

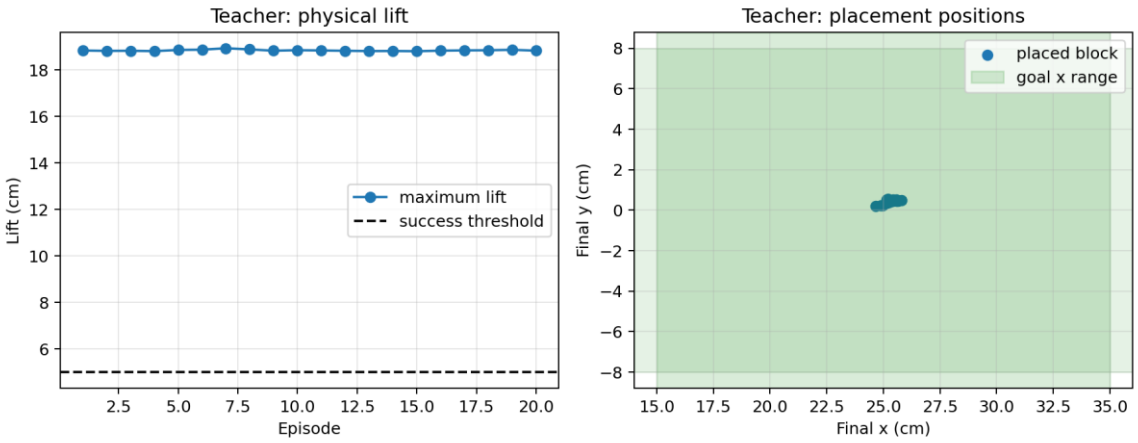
- **モデル**：ACT VAE 無効
- **学習ステップ**：5,000
- **バッチサイズ**：8
- **学習率**：1e-4
- **チャンクサイズ**：32
- **モデル次元**：128
- **エンコーダ層とデコーダ層**：2 層と 1 層

- **パラメータ数**：670,243
- **CPU スレッド**：12
- **学習時間**：277.01 秒
- **最終 L1 loss**：0.08205
- **最小 L1 loss**：0.05039

当初は各推論周期の指令差を実測関節角の前後 0.08 rad に制限した。しかし trajectory controller の追従遅れにより、再計画時にモデルが過去の軌道位置から予測し直す現象が起きた。関節の絶対上下限は維持し、実測状態との差分制限だけを 0.50 rad へ緩和した結果、配置まで完了したため、正式評価は 70 秒、差分制限 0.50 rad で実施した。

4. 結果

4.1 教師データと学習結果



採用した教師データの持上げ量と配置位置

27 試行のうち、Gazebo の物体位置で物理成功と判定した試行は 24 件だった。そのうち、工程ラベルがすべて揃い、実把持にも成功した 20 エピソードを学習に採用した。把持指令だけで搬送量が 0 m だった 3 件と、工程イベントが欠けた 4 件は除外した。

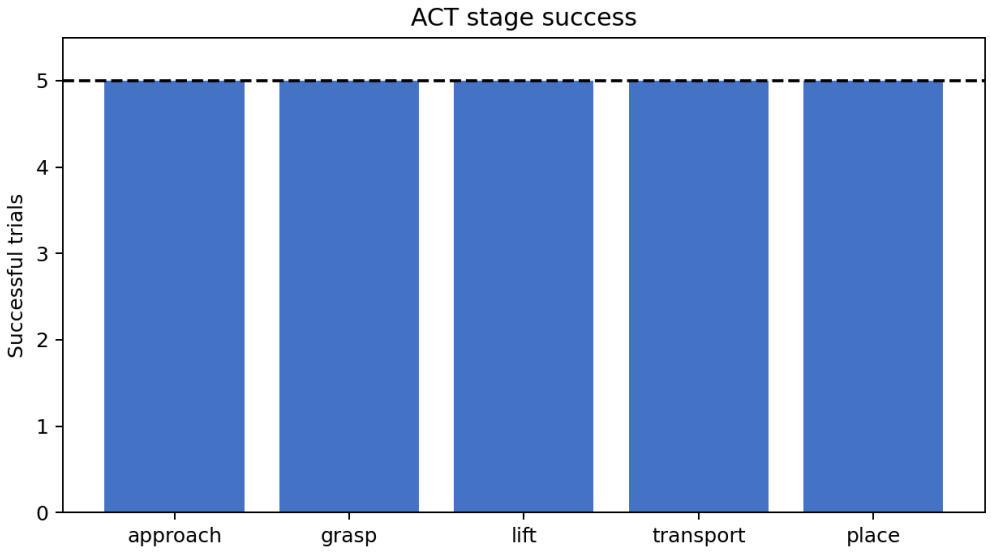
- **収集試行**：27 試行
- **Gazebo 物体位置での物理成功**：24 試行 88.89 パーセント
- **学習採用**：20 エピソード
- **総フレーム数**：12,444 フレーム
- **平均フレーム数**：622.2 フレーム毎エピソード
- **平均時間**：約 31.11 秒毎エピソード

採用した 20 エピソードの平均最大持上げ量は 0.18839 m、平均平面移動量は 0.27393 m だった。決定論的 ACT の学習では loss が低下し、最終 L1 loss は 0.08205、最小 L1 loss は 0.05039 となった。



ACT の CPU 学習 loss

4.2 正式評価



ACT の工程別成功数

評価は 5 試行で行った。初期位置から 5 cm 以上持ち上がること、平面移動が 15 cm 以上であること、最終 x が 0.15 m から 0.35 m、最終 y の絶対値が 0.08 m 以下であることを成功条件とした。把持はグリッパ閉指令と持上げ条件の両方、配置は目標領域への到達とグリッパ再開を用いて判定した。

- **試行 0**：最大持上げ cm 16.82、平面移動 cm 32.23、最終 x m 0.2954、最終 y m 0.0289、最終 z m 1.0150、判定 成功
- **試行 1**：最大持上げ cm 18.94、平面移動 cm 32.19、最終 x m 0.2957、最終 y m 0.0270、最終 z m 1.0400、判定 成功
- **試行 2**：最大持上げ cm 18.56、平面移動 cm 32.22、最終 x m 0.2957、最終 y m 0.0279、最終 z m 1.0400、判定 成功
- **試行 3**：最大持上げ cm 19.03、平面移動 cm 31.92、最終 x m 0.2926、最終 y m 0.0278、最終 z m 1.0400、判定 成功
- **試行 4**：最大持上げ cm 16.44、平面移動 cm 33.44、最終 x m 0.3055、最終 y m 0.0361、最終 z m 1.0150、判定 成功

成功率は 100 パーセントで、接近、把持、持上げ、搬送、配置はいずれも 5 回成功した。平均最大持上げ量は 0.17958 ± 0.01102 m、平均平面移動量は 0.32400 ± 0.00532 m、平均最終位置は (0.29698, 0.02953, 1.029999) m だった。

最終 z は 1.015 m と 1.040 m に分かれた。全試行で目標領域へ到達してグリッパは開いたが、3 試行ではブロックが開いた指先付近に残った。追加試行では最終 z が 1.015 m となり、ブロックはテーブル面に置かれた。

5. 考察

5.1 学習結果と制御系の関係

本実験で安定した搬送を学習できた主な要因は、ブロックの初期位置を固定し、再現性の高い MoveIt 教師から得たデータのうち、物体座標で物理成功を確認できた試行だけを採用したことである。収集時と評価時の双方で Gazebo の物体位置を測定したため、ノードが正常終了していても実際には把持できていない試行を排除できた。このように教師データの品質と成功判定を物理量で管理したことが、画像を用いない 5 次元関節状態だけのモデルでも高い再現性を得られた理由と考えられる。

一方、学習 loss の低下だけでは実タスクの成功を保証できなかった。ACT が将来 32 点の関節指令を予測しても、実測状態との差分制限が厳しく、trajectory controller の追従が遅れると、再計画のたびに過去の軌道へ戻る現象が生じた。差分制限を 0.50 rad へ緩和したことで配置まで到達したことから、方策モデルだけでなく、推論周期、指令の送り方、controller の追従特性を一体として調整する必要がある。また、今回は固定位置から生成されたほぼ単峰な教師軌道であったため、VAE を無効化した決定論的 ACT の方が推論軌道を安定させやすかった。ただし、VAE 版を同じ 5,000 ステップまで学習した比較は行っておらず、この結果は多様な教師データに対する VAE の有効性を否定するものではない。

5.2 配置品質と一般化の課題

正式評価では全試行が目標領域へ到達し、グリッパも再び開いたため、搬送タスクとしての成功率は 100 パーセントだった。しかし、5 回中 3 回は最終 z がテーブル面より 2.5 cm 高く、ブロックが開いた指先付近に残った。したがって、現在の成功判定は目標領域への搬送と解放指令の実行を示す一方、対象物をテーブル面へ安定して静置できたことまでは示していない。完全な配置を評価するには、教師動作の下降、解放、退避を明確に分離し、最終 z の許容範囲、解放後の静止時間、物体速度を判定条件へ加える必要がある。

また、本モデルはブロック位置を固定し、画像や物体座標を観測に含めていないため、学習した関節軌道を同一条件で再現する能力を評価したものといえる。位置が変化したブロックへの接近や把持には、現在の 5 次元関節状態だけでは必要な情報が不足する。今回の結果は固定条件における模倣学習の成立を示すが、未知位置への一般化性能を示すものではない。この点を改善するには、カメラ画像または物体座標を観測へ追加し、複数の初期位置から教師データを収集した上で、位置をランダム化した条件で評価する必要がある。

今後は、カメラ画像または Gazebo の物体座標を観測へ追加し、複数位置から教師データを収集する必要がある。さらに、評価試行数を 30 回から 100 回へ増やし、位置をランダム化した未知条件で成功率を測定することで、一般化性能を統計的に検証できる。action chunk の長さと temporal ensemble の比較、controller へ chunk 全体を時刻付きで送信する方法も、追従遅れと再計画の影響を減らす候補となる。

6. 出典

1. T. Z. Zhao, V. Kumar, S. Levine, and C. Finn, “Learning Fine-Grained Bimanual Manipulation with Low-Cost Hardware,” Robotics: Science and Systems, 2023. https://arxiv.org/abs/2304.13705

2. Hugging Face, “LeRobot.” https://github.com/huggingface/lerobot

3. MoveIt, “Pick and Place.” https://moveit.picknik.ai/main/doc/examples/pick_place/pick_place_tutorial.html

4. ROS 2 Documentation, “Humble.” https://docs.ros.org/en/humble/

5. Gazebo, “Gazebo Sim Documentation.” https://gazebosim.org/docs

6. 松尾・岩澤研究室, “Physical AI Training.” https://github.com/matsuolab/pai_training

6. 出典

1. T. Z. Zhao, V. Kumar, S. Levine, and C. Finn, “Learning Fine-Grained Bimanual Manipulation with Low-Cost Hardware,” Robotics: Science and Systems, 2023. https://arxiv.org/abs/2304.13705

2. Hugging Face, “LeRobot.” https://github.com/huggingface/lerobot

3. MoveIt, “Pick and Place.” https://moveit.picknik.ai/main/doc/examples/pick_place/pick_place_tutorial.html

4. ROS 2 Documentation, “Humble.” https://docs.ros.org/en/humble/

5. Gazebo, “Gazebo Sim Documentation.” https://gazebosim.org/docs

6. 松尾・岩澤研究室, “Physical AI Training.” https://github.com/matsuolab/pai_training